Fine-tuning et RAG

EMSI - Université Côte d'Azur
Richard Grin
Version 1.30.1 - 26/9/25

1

Plan du support

2

Principaux problèmes LMs publics

- Ils peuvent halluciner
- Pas de connaissances sur les données privées des entreprises car ils n'y ont pas eu accès pendant leur apprentissage
- Leurs connaissances s'arrêtent à la date de fin de leur apprentissage
- Ils ne peuvent donc pas être utilisés tels quels dans une application d'entreprise

3

Pour atténuer les problèmes

- Prompt engineering (déjà étudié)
- Fine-tuning qui modifie le LM (change ses paramètres)
- RAG qui ne modifie pas le LM mais qui, pour chaque question,
  - recherche dans des documents fiables des informations supplémentaires pertinentes pour y répondre
  - les ajoute au prompt pour que le LM puisse les utiliser

4

Fine-tuning

5

Fine-tuning (réglage fin)

- **Entrainement complémentaire** d'un modèle d'IA existant (OpenAi, Gemini,...), sur de nouvelles données liées à une tâche spécifique, à un nouveau domaine, ...
  - Le pré-entrainement du modèle existant a permis d'apprendre les structures de langage, la syntaxe, la sémantique et des connaissances générales
  - Le fine-tuning **modifie les paramètres du modèle** ; le nouveau modèle acquiert des connaissances sur une tâche spécifique, dans un domaine particulier, ou apprend à converser avec un style ou un ton défini

6

Entrainement pour fine-tuning

- On fournit à l'API des paires de texte (entrée, et sortie attendue) pour entrainer le modèle
- Chaque LM a son propre format pour les données d'entrainement
- Pour avoir un impact significatif sur le modèle de base pré-entrainé, il faut l'entrainer sur au moins plusieurs centaines (pour une tâche très spécifique) à plusieurs milliers d'exemples ou davantage

7

Coûts

- L'entrainement du fine-tuning est bien plus coûteux que l'utilisation du modèle ; il nécessite des machines puissantes et beaucoup de temps
- Les données utilisées pendant l'entrainement sont longues et complexes à créer, avec intervention humaine
- Le fine-tuning est de loin la solution la plus coûteuse pour modifier le comportement du modèle

8

Options pour le fine-tuning

- Le fine-tuning étant long et très coûteux, des options ont vu le jour (soft-prompting, T-few, LORA, adapters, pré-entrainement continu, …)
- Ces options offrent un compromis intéressant entre coût et personnalisation mais n'égalent pas la performance d'un fine-tuning complet sur des tâches complexes

9

Retrieval-Augmented Generation (RAG)

- Bases
- Techniques avancées

10

Bases

11

Présentation

- Le RAG est une technique qui permet de fournir à un LM des données externes fiables pour lui permettre de répondre aux questions
- Ces données peuvent être contenues dans des documents d'entreprise de haute expertise dans un domaine, ou des documents récents sur lesquels le LM n'a pas été entrainé
- L'exactitude et la pertinence des réponses du LM sont ainsi améliorées et le LM peut indiquer les sources d'information qu'il a utilisées pour répondre

12

Utilisation des données

- Au contraire du fine-tuning, les données fournies au LM ne modifient pas les paramètres du LM
- Ces données sont automatiquement ajoutées au prompt envoyé au LM et ainsi le LM pourra les utiliser pour répondre aux questions

13

Sources des données externes

- Articles
- Podcasts
- Vidéos
- Recherches sur Internet
- Fichiers de tous types (PDF, …)
- BD structurées (relationnelles) ou semi-structurées (noSQL)
- Bases de connaissances
- API ou moteurs de recherche (API d'encyclopédies, Google, Bing)
- …

14

Avantages du RAG

- Réduction des hallucinations : le LM peut s'appuyer sur des sources fiables et adaptées au type de questions prévu pour l'application
- Accès à des informations privées de l'entreprise
- Accès à des informations à jour, plus récentes que la fin de l'entrainement du LM
- Plus souple et moins coûteux que le fine-tuning
- Meilleur explicabilité des réponses du LM car les sources utilisées peuvent être citées

15

- Dans la suite on appellera
  - « document » une source d'information externe, qui pourra être un document entier ou, le plus souvent, un « chunk », un morceau de document, obtenu par découpage en morceaux d'un document
  - « question » une question posée à un LM avec, éventuellement, l'historique de la conversation

16

Exemples d'utilisation du RAG

- Service client intelligent ; chatbot pour répondre aux clients de l'entreprise
- Interroger le LM sur des fichiers PDF qui contiennent les règles de fonctionnement d'une entreprise
- Résumer un document ou une page Web
- Interroger le modèle sur une vidéo YouTube
- Assistance juridique en s'appuyant sur des lois, des règlements et la jurisprudence
- Aide à l'apprentissage ou à la recherche dans un domaine particulier
- Support technique avancé avec manuels techniques

17

2 grandes phases pour le RAG

1. Ingestion des documents dans le système de RAG : nettoyage des documents, découpage en morceaux, ajout de métadonnées, enregistrement des morceaux
2. Le système génère la réponse en retrouvant les documents les plus pertinents pour répondre à la question, pour les envoyer au LM avec la question

- Ces 2 phases sont **indépendantes** et se déroulent le plus souvent à des moments différents

18

Phase 2 qui génère la réponse

- Elle peut elle-même être décomposée en 2 phases qui s'exécutent consécutivement :
  - Retrieval (récupération) / augmentation : parmi les données « ingérées » dans la phase 1, le système sélectionne les morceaux les plus pertinents pour répondre à la question, et les ajoute à la question
  - Génération : le tout (informations pertinentes + question + historique de la conversation éventuel) est envoyé au LM qui génère une réponse en utilisant ses capacités linguistiques et de compréhension

19

Phases en images

Phase 1 :

Phase 2 : Question +

(Source Oracle University)

20

Préparation des données

- Pendant la phase d'ingestion, la préparation des documents est très importante car elle permet d'améliorer grandement les résultats et d'économiser des ressources
- Le processus peut être complexe mais il ne s'effectue qu'une seule fois quand les documents sont ajoutés
- Il faut commencer par nettoyer les documents pour les uniformiser et enlever les parties non pertinentes
- Le plus souvent les documents sont ensuite découpés en morceaux (chunks)
- Des métadonnées peuvent être ajoutées

21

Nettoyage des documents

- Suppression des éléments non pertinents : en-têtes, pieds de page, signatures automatiques des emails, mentions légales, informations répétées à chaque page (nom de l'auteur, titre du document, du chapitre, date), publicités, …
- Supprimer les éléments de mise en forme ; par exemple dans pages HTML
- Corriger les fautes d'orthographe et de grammaire
- Supprimer les contenus obsolètes ou qui ne sont évidemment pas pertinents pour le type de question qui sera posé
- Supprimer les liens externes non pertinents

22

Autres préparations

- Uniformisation des textes : supprimer espaces ou saut de ligne superflus, tout mettre en minuscules ?, remplacer les caractères accentués ?
- Remplacer les sigles ou abréviations par leur signification ; on peut aussi garder l'abréviation mais ajouter la signification
- Les données spéciales (tables, images) peuvent nécessiter des traitements supplémentaires
- …

23

Chunks (morceaux) (1/2)

- Les documents externes sont le plus souvent découpés en morceaux pendant la phase d'ingestion
- On peut ainsi mieux cerner les passages des documents qui sont pertinents pour la question posée
- D'autre part, on réduit ainsi le volume de données à traiter, ce qui donne des réponses plus rapides et une meilleure gestion des ressources et des coûts
- De plus, les modèles d'embeddings ont une taille limite pour le texte à transformer en embedding

24

Chunks (morceaux) (2/2)

- Les morceaux sont le plus souvent de taille fixe (200 à 300 mots est une taille courante) ; des tests sont souvent nécessaires pour trouver la meilleure taille
- Les morceaux peuvent se chevaucher légèrement pour éviter de couper au milieu d'une phrase, d'un paragraphe, ou d'une idée importante
- Essayer de tenir compte des phrases et des paragraphes (éviter de les couper au milieu) ; si le document est structuré (sections par exemple), essayer de tenir compte des structures

25

Sélection des données

- Il n'est pas envisageable d'ajouter dans chaque prompt toutes les données ingérées Pourquoi ?
- Dans la phase 2, il faut donc un moyen de retrouver les données les plus pertinentes pour répondre à la question

26

Pertinence des documents

- Plusieurs moyens de trouver les documents les plus pertinents pour répondre à une question :
  - Trouver les documents qui ont les embeddings les plus similaires à la question
  - Associer des mots-clés aux documents
  - Un mode hybride avec mots-clés et embedding
  - Une étape initiale (types précédents), suivie de techniques pour améliorer les résultats ou la rapidité des traitements (on verra, par exemple, le reranking, avec des modèles spécialisés pour évaluer la pertinence de documents)

27

RAG avec embeddings

- La façon la plus classique de faire du RAG
- Les chunks sont transformés en embeddings qui sont enregistrés dans un entrepôt (magasin d'embeddings), avec les textes correspondants ou avec une clé qui permet de retrouver rapidement ces textes
- Des modèles d'embedding sont utilisés pour cette transformation
- Les entrepôts sont le plus souvent des BDs vectorielles
- Les index de ce type de BDs permettent de faire des recherches de similarités très rapides

28

Avantages des embeddings

- Ils capturent les sens des mots et des textes, ce qui est bien plus souple que la correspondance exacte avec des mots-clés
- Exemple :
  - « traitement du cancer » et « thérapies contre les tumeurs » auront des embeddings proches, sans avoir aucun mot en commun
  - Pour répondre à une question sur les traitements du cancer, les documents traitant des thérapies contre les tumeurs seront ainsi retrouvés dans la phase de récupération

29

Utilisation de mots-clés

- Des mots-clés peuvent permettre de retrouver les morceaux de document les plus pertinents
- Les mots-clés sont enregistrés dans les métadonnées des morceaux enregistrés
- Les mots-clés associés aux documents et aux questions peuvent être donnés explicitement mais ils peuvent être extraits automatiquement par des utilitaires spécialisés (KeyBERT ou keyword-spacy, par exemple)
- Pour la récupération on peut effectuer un premier filtrage « large » des morceaux en se basant uniquement sur les mots-clés, pour accélérer le traitement

30

TF-IDF

- D'autres techniques comme TF-IDF (*Term Frequency-Inverse Document Frequency*) peuvent être utilisées pour accélérer la recherche des morceaux les plus pertinents
- Les mots d'un document ont un poids qui est fonction
  - de sa fréquence dans le document (TF, Term Frequency)
  - de la fréquence inverse dans l'ensemble des documents (IDF, Inverse Document Frequency)
- Les mots qui apparaissent fréquemment dans un document, mais rarement dans d'autres, sont considérés comme particulièrement significatifs

31

Etapes ingestion

1. Chacun des documents est transformé en un embedding
2. Traitement optionnel des embeddings :
   - normalisation pour faciliter les calculs de similarité (norme des vecteurs égale à 1)
   - ajout de métadonnées, par exemple le titre du document qui contient le morceau, ou des mots-clés
3. Stockage des embeddings dans une BD vectorielle, avec le document correspondant et les éventuelles métadonnées

32

Etapes récupération - génération

- La question est transformée en embedding avec le même modèle que les documents enregistrés
- Son embedding est comparé aux embeddings enregistrés
- Les n (par exemple, 10) documents qui ont les embeddings les plus similaires à l'embedding de la question sont ajoutés au prompt, le plus souvent devant la question, les plus pertinents en premier
- Une étape optionnelle de « reranking » peut réordonner les embeddings plus finement dans le prompt
- Le tout est envoyé au LM qui répond à la question

33

Template pour récupération

- Souvent l'augmentation utilise un template pour recevoir le contexte récupéré
- Par exemple,

```
En t'appuyant sur les informations suivantes, réponds à la question de l'utilisateur
Contexte :
{{contexte}}

Question de l'utilisateur :
{{question-utilisateur}}
```


34

Température du LM

- Pour le RAG il est conseillé de réduire la température du LM pour l'inciter à ne pas trop faire preuve de « créativité », à se limiter à choisir les mots les plus probables, à ne pas « divaguer »
- En effet, un des buts principaux du RAG est d'obtenir des résultats fiables, de limiter les hallucinations
- Température recommandée : entre 0 et 0,3

35

Priorité informations récupérées

- Un LM considère le contenu du prompt comme fiable et donne souvent la priorité aux informations récupérées qui sont ajoutées au prompt, par rapport aux connaissances acquises lors de l'apprentissage
- Pour renforcer cette priorité, le prompt peut contenir ce type de phrase : « En utilisant uniquement les informations fournies dans le texte ci-dessus » (si l'ajout est fait avant la question)
- D'autres techniques plus avancées peuvent aussi être utilisées

36

Paramètres

- Taille des morceaux
- Nombre d'embeddings récupérés
  - Un trop grand nombre peut nuire à la qualité car les informations importantes risquent d'être noyées dans des informations moins intéressantes
  - Un trop petit nombre risque de manquer des informations importantes
- Il faut tester pour choisir les valeurs de ces paramètres qui donnent les meilleurs résultats

37

Evaluation des performances

- Il est important de pouvoir juger de la qualité des résultats pour choisir les meilleures valeurs des paramètres en testant sur des questions dont on connait les réponses
- Un autre LM peut aider à juger de la qualité des réponses fournies par le RAG

38

Techniques avancées de RAG

39

Indexation

- Les embeddings sont indexés pour retrouver plus rapidement les embeddings les plus pertinents
- Toutes les BDs vectorielles permettent l'indexation

40

Ajout de mémoire

- S'il peut y avoir une conversation entre l'utilisateur et le LM, il faut ajouter un historique de la conversation au prompt

41

Métadonnées

- Peuvent être enregistrées avec les morceaux de texte et les embeddings pour accélérer la récupération, améliorer la pertinence des documents et la qualité de la réponse
- Peuvent contenir le titre du document, sa source (livre, site Web, …), la date de publication, les auteurs, …
- Au moment de la récupération, elles offrent la possibilité de filtrer des documents avant la recherche par mots-clés ou par similarité
- Les BD vectorielles permettent souvent d'associer des métadonnées aux embeddings

42

Exemples utilisation métadonnées

- Catégorie : Filtrer par sous-domaine du droit (par exemple, droit civil, droit commercial, droit du travail)
- Date : Filtrer par date de publication d'articles scientifiques pour ne garder que les articles récents ou ceux publiés dans une certaine période
- Confidentialité : Filtrer les documents selon leur niveau de confidentialité pour restreindre l'accès (public, interne, confidentiel)

43

Reranking

- Solution possible si une recherche sémantique ne donne pas un résultat satisfaisant
- Un reclassement (reranking) peut permettre d'obtenir un meilleur résultat : les items retrouvés sont réexaminés en appliquant un autre modèle IA ou des méthodes pour avoir un résultat plus pertinent
- On peut ainsi combiner plusieurs approches, ou appliquer une méthode plus précise, mais plus lourde et plus coûteuse, sur un nombre limité d'items

44

Routage

- Souvent les données privées des entreprises sont conservées dans des endroits et des formes diverses
- Plutôt que de parcourir toutes les sources de données à chaque prompt, un routage permet de ne consulter que certaines de ces sources de données
- Le routage peut s'appuyer sur
  - Des règles diverses (autorisations de l'utilisateur, service qui a émis la requête, …)
  - Des mots-clés
  - Des calculs de similarité
  - Un choix fait par le LM

45

Utilisation d'outils

- Des outils, par exemple pour effectuer des calculs complexes ou pour retrouver les cours de devises, peuvent être utilisés pendant la phase d'augmentation de la question

46

2 techniques pour RAG

- RAG sequence model : technique la plus utilisée car la plus simple et suffisante dans la plupart des cas ; les documents les plus pertinents sont récupérés et ajoutés à la question et à l'historique de la conversation ; le tout est envoyé au LM qui génère les tokens de la réponse
- RAG token model : souvent plus précis mais plus difficile à mettre en œuvre et plus coûteux; chaque token est généré par le LM en tenant compte des documents les plus pertinents compte tenu des tokens déjà générés pour la réponse ; intéressant quand différentes parties de la réponse sont associées à des documents différents

47

RAG multi-modal

- Prend en compte non seulement du texte mais aussi d'autres types de media comme l'audio, la vidéo, les images
- A l'architecture de base il faut ajouter des traitements pour prendre en compte ces médias car les LMs sont centrés essentiellement sur le texte (et un peu les images)
- Par exemple, les vidéos sont représentées par des captures d'écran et par la transcription de la bande audio

48

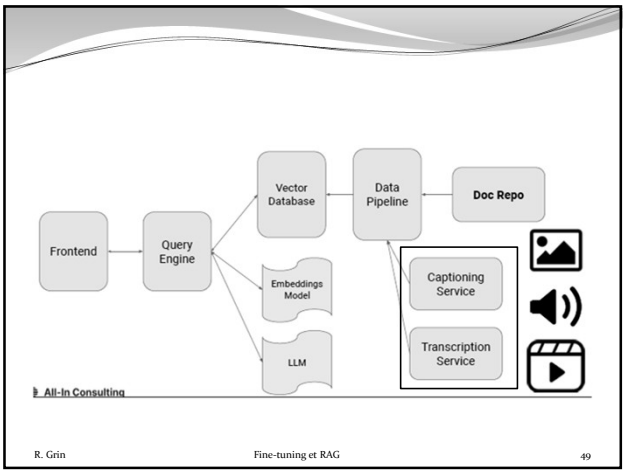

49

RAG récursif

- Une requête peut être obtenue plus efficacement par plusieurs résultats intermédiaires qui sont agrégés pour obtenir une réponse
- Les étapes intermédiaires permettent de mieux cerner les besoins et d'aider le LM à utiliser les bonnes informations ; les 1ères étapes peuvent aussi influencer les étapes suivantes pour optimiser la recherche

50

Exemple

- Une 1ère étape recherche dans une base qui contient des résumés d'articles, ce qui indique dans quels articles rechercher les détails de l'information cherchée
- Voir LlamaIndex (https://www.llamaindex.ai/)

51

Prompt engineering vs fine-tuning vs RAG

52

- Comparaison entre les 3 façons de prendre en compte des données sur lesquelles un LM n'a pas été entrainé

53

Avantages et inconvénients (1/3)

- **Prompt engineering** :
  - simple, souple et rapide
  - **mais**
    - difficile de mettre à l'échelle (solution ad hoc pas généralisable ; peut dépendre des versions des LMs)
    - résultats aléatoires
    - le LM doit déjà connaitre le domaine concerné par la question

54

Avantages et inconvénients (2/3)

- **Fine tuning** :
  - performant
  - pas limité par la taille maximale du contexte
  - parfait pour répondre avec un certain style
  - expert dans un domaine
  - **mais**
    - demande une préparation lourde, coûteuse en temps et argent
    - cette préparation est à répéter quand les données changent
    - moins précis et moins souple que le RAG
    - danger de perte de capacités générales

55

Avantages et inconvénients (3/3)

- **RAG** (souvent la meilleure solution) :
  - permet de réduire les hallucinations en fournissant des informations fiables avec des sources vérifiables
  - peut fournir des informations différentes selon le type d'utilisateur, par exemple en réservant des informations sensibles à des utilisateurs privilégiés
  - permet de tester facilement plusieurs LMs
  - **mais**
    - traitement à répéter à chaque recherche (donc moins rapide que le fine tuning)
    - parfois difficile à mettre en œuvre
    - pas adapté pour certaines tâches, par exemple parler en imitant une personne ou répondre avec un certain style
    - lourd à gérer si documents très nombreux

56

Que choisir ? (1/4)

- Le prompt engineering seul ne convient que si le LM connait déjà le domaine de la question
- Sinon, il sera nécessaire d'ajouter des informations dans le prompt, et alors il faudra que ces informations ne soient ni trop volumineuses ni difficiles à trouver

57

Que choisir ? (2/4)

- Le fine tuning convient bien pour
  - répondre à des questions dans un domaine bien défini et spécifique avec des informations **stables dans le temps** ; par exemple assistance technique sur des produits de base, compréhension de termes médicaux
  - générer du contenu qui n'est pas basé sur des informations incluses dans des documents ; par exemple, imiter une voix, adopter un certain ton ou style
  - reconnaitre des patterns ou des sentiments ; par exemple, classer des emails envoyés par des clients : problèmes techniques, retours, satisfaction, …

58

Que choisir ? (3/4)

- Le RAG convient bien pour
  - des tâches nécessitant des informations actualisées en temps réel ; par exemple, assistant pour aider les clients à investir en bourse
  - obtenir des réponses basées sur des documents d'entreprise nombreux et qui peuvent être modifiés à tout moment ; par exemple, FAQ, manuels de procédures
  - outil de recherche dans des bases très volumineuses et qui sont continuellement mises à jour ou recherche sur le Web ; par exemple recherche d'articles scientifiques à jour

59

En résumé, que choisir ? (4/4)

- Le RAG permet d'**améliorer les réponses d'un modèle** grâce à des informations supplémentaires pertinentes et à jour
- Mais il **ne modifie pas fondamentalement le comportement ou le style linguistique du modèle ;** en ce cas, le fine-tuning sera meilleur
- Le Fine-tuning ne permet pas d'actualiser rapidement le modèle avec de nouvelles informations et il est coûteux en temps et en argent
- Le plus souvent, le RAG, ou une combinaison des 2 techniques, sera donc la meilleure solution

60

Combinaison des techniques

- Le prompt engineering, le fine-tuning et le RAG peuvent être combinés sur un même projet pour en tirer le meilleur parti ; par exemple

1. Commencer par le plus simple, avec des techniques de prompt engineering
2. Ajouter du RAG s'il manque des informations pour bien répondre
3. Faire du fine-tuning sur le LM de base du RAG pour le spécialiser dans un domaine ou/et si le ton, le style ou le format des réponses ne conviennent pas

61

Et la sécurité ?

- Toutes ces techniques présentent le risque de fuites de données sensibles
- Il faut s'assurer que les données rendues accessible au LM resteront privées :
  - ne seront pas utilisées par le LM ; lire attentivement les politiques d'utilisation des données du LM ; si nécessaire, signer un contrat avec le fournisseur de LM
  - n'apparaitront pas en réponse à des questions posées par des utilisateurs malveillants
- Il faut anonymiser les données sensibles transmises au LM

62

Bases de données vectorielles

63

BDs vectorielles

- Fréquemment utilisées pour le RAG
- BD pour stocker et rechercher des vecteurs de données
- Ces BDs peuvent faire des recherches par similarités, plutôt que de trouver des correspondances exactes
- Des index permettent accélérer les recherches

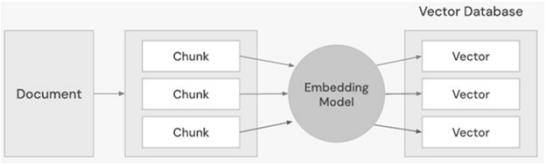

64

Principales caractéristiques

- Stockage et gestion d'un très grand nombre de vecteurs (jusqu'à des milliards)
- Recherche rapide des vecteurs similaires à un vecteur (recherche ANN, Approximate Nearest Neighbor) ; indexation adaptée à cette recherche
- Gestion de métadonnées associées aux vecteurs ; par exemple titre, date de parution, auteurs, emplacement du contenu d'articles
- Souvent intégration avec frameworks ML
- Forte utilisation des index
- Support multimodal (texte, image, audio)

65

Index

- Les vecteurs sont indexés pour permettre des recherches de similarité rapides
- Utilisent des techniques spéciales pour accélérer les recherches et réduire l'occupation de la mémoire

66

Exemples d'utilisation

- Recherche sémantique (pour RAG en particulier)
- Recommandation de contenu (pour achats de produits similaires)
- Recherche d'images ou de vidéos (par caractéristiques visuelles)

67

Contenu de la BD vectorielle

- Une BD vectorielle peut stocker les textes associés aux embeddings ou ne stocker que les informations nécessaires pour retrouver ces textes ailleurs (par exemple, dans une base de données classique ou un système de stockage)
- Elle peut aussi contenir des métadonnées qui peuvent alors servir à filtrer les résultats des requêtes (date de création, mots-clés, catégories,…)

68

Types de recherche

- Les recherches dans les BD vectorielles sont le plus souvent des recherches sémantiques, appelées aussi recherches denses, qui utilisent des embeddings
- De nombreuses BD vectorielles peuvent aussi faire des recherches par mots-clés avec des filtres basés sur les métadonnées
- Ces BD vectorielles peuvent aussi faire des recherches hybrides qui combinent la précision et la rapidité des recherches par mots-clés et la compréhension du sens des recherches sémantiques

69

Exemples de recherche hybride

- Si les données sont très nombreuses, un système peut effectuer d'abord une recherche rapide par mots-clés pour réduire le nombre d'items et ensuite faire une recherche sémantique sur le résultat
- Utiliser une recherche par mots-clés pour obtenir un premier ensemble de résultats, puis réordonner ces résultats en fonction des similarités de vecteurs des documents
- Il est possible d'attribuer un poids à chacune des 2 recherches pour obtenir le résultat final
- Les résultats d'une recherche dense peuvent être filtrés pour éliminer les items qui n'ont pas certains mots-clés

70

BD vectorielle en mémoire

- Les TPs utilisent une BD en mémoire très simple `InMemoryEmbeddingStore` qui évite l'installation d'une « vraie » BD vectorielle
- A part la création de l'`EmbeddingStore`, tout le reste du code Java est identique pour toutes les BDs vectorielles, grâce à LangChain4j
- Dans une application d'entreprise il faut utiliser une des « vraies » BDs vectorielles supportées par LangChain4j pour ne pas perdre les embeddings entre 2 sessions de travail et profiter des index

71

Produits supportés par LangChain4j

- Chroma
- Milvus
- Weaviate
- Pinecone
- Vespa (Yahoo!)
- Qdrant
- Elasticsearch (avec plugins spécialisés)
- AI Vector Search (Oracle)
- Redis
- Astra DB
- Cassandra

72

Chroma

- BD vectorielle gratuite (https://www.trychroma.com/home) et open source (https://github.com/chroma-core/chroma)
- On peut l'installer en local ; le plus simple est d'utiliser une image Docker
- Fournit une API utilisable à distance mais le plus simple est de l'utiliser par l'intermédiaire de LangChain4j

73

Chroma - Installation

- Le plus simple est de l'installer avec Docker en tapant cette commande dans un terminal :
  docker pull chromadb/chroma
- Une autre façon est d'aller dans Docker Desktop et de cliquer sur l'icône de Docker Hub pour chercher « chromadb » pour récupérer chromadb/chroma
- Dans Docker Desktop on peut alors lancer l'exécution de chromadb/chroma en cliquant sur le triangle « Run » ; dans la fenêtre qui s'ouvre, clic sur « Optional settings » et associer alors les ports 8000 de l'hôte et du container

74

Chroma - Utilisation (1/2)

- Dans pom.xml :

```
<dependency>
    <groupId>dev.langchain4j</groupId>
    <artifactId>langchain4j-chroma</artifactId>
    <version>****</version>
</dependency>
```


75

Chroma - Utilisation (2/2)

- Pour créer l'`EmbeddingStore` :

```
EmbeddingStore<TextSegment> embeddingStore =
    ChromaEmbeddingStore.builder()
    .baseUrl("http://localhost:8000/")
    .collectionName("ma-collection")
    .build();
```

- Tout le reste est identique à l'utilisation de `InMemoryEmbeddingStore`

76

Code pour utiliser Chroma

```
EmbeddingStore<TextSegment> embeddingStore =
    ChromaEmbeddingStore.builder()
        .baseUrl("http://localhost:8000")
        .collectionName("ma-collection")
        .build();
  // Tout le reste du code ne dépend pas de Chroma
  EmbeddingModel embeddingModel =
      new AllMiniLmL6V2EmbeddingModel();
  ...
}
```


77

RAG avec LangChain4j

- Généralités et RAG « facile »
- Classes et interfaces LangChain4j

78

LangChain4j

- LangChain4j fournit plusieurs types Java pour faciliter le RAG
- On verra d'abord un « RAG facile » pour faire du RAG sans configurations ni optimisations (https://docs.langchain4j.dev/tutorials/rag)
- Les classes qui permettent de construire des RAGs plus adaptés aux cas particuliers seront étudiées ensuite

Phase 1 du RAG - Ingestion

- On indique
  - L'origine des données externes utilisées pour le RAG (base de données, documents d'entreprise,…)
  - Où seront entreposées les morceaux et leur embedding

Exemple RAG facile (1/3)

```
List<Document> documents = FileSystemDocumentLoader.
    loadDocuments("/home/langchain4j/documentation");
EmbeddingStore<TextSegment> embeddingStore =
    new InMemoryEmbeddingStore<>();
EmbeddingStoreIngestor.ingest(documents, embeddingStore);
```

Pour que ce code fonctionne, il faut ajouter une dépendance pour langchain4j-easy-rag

Phase 2 du RAG

- Création d'un assistant IA (avec `AIServices`) en précisant le magasin d'embeddings utilisée pour le RAG

Exemple RAG facile (2/3)

```
public interface Assistant {
  String chat(String userMessage);
}
```

Interface implémentée par l'assistant IA

Exemple RAG facile (3/3)

```
ChatModel model = …;
Assistant assistant = AiServices.builder(Assistant.class)
    .chatModel(model)
    .chatMemory(MessageWindowChatMemory.withMaxMessages(10))
    .contentRetriever(
        EmbeddingStoreContentRetriever.from(embeddingStore))
    .build();

String answer =
  assistant.chat("Comment faire du RAG avec LangChain4j ?");
```

Il suffit de créer l'assistant et de le configurer en indiquant le modèle de chat et le magasin d'embeddings.
Tout le reste est implémenté par LangChain4j, grâce à `AIServices`

Types du code

- `Document` : représente un fichier local ou une page Web qui contient du texte
- `FileSystemDocumentLoader` : charge des fichiers pour obtenir des documents
- `TextSegment` : morceaux de texte (chunks) et métadonnées associées
- `EmbeddingStore<TextSegment>` : magasin pour embeddings de `TextSegments`
- `EmbeddingStoreIngestor` : Pipeline pour l'ingestion de documents dans un magasin d'embeddings
- `EmbeddingStoreContentRetriever` : retrouve dans un magasin d'embeddings les `Contents` (enveloppes de `TextSegment`) les plus similaires à la question

85

Classes et interfaces pour RAG

- Phase 1 : chargement (ingestion) des `Documents`
- Phase 2 : récupération (retrieval) des données pertinentes et augmentation du prompt

86

RAG - Ingestion

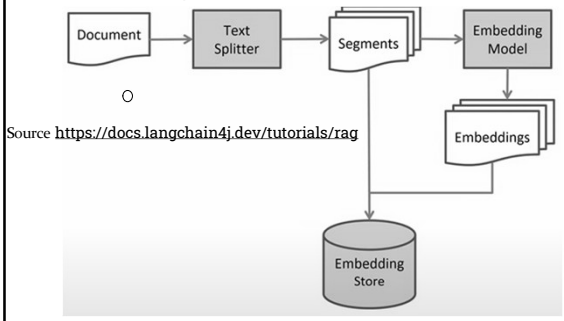

Source https://docs.langchain4j.dev/tutorials/rag

87

Exemple schématique simple

```
// Création d'un document avec un DocumentParser
DocumentParser documentParser = ... ;
Document document = UnDocumentLoader.loadDocument(
    cheminFichier, documentParser);
// Découper le document en morceaux (chunks)
DocumentSplitter splitter =
    DocumentSplitters.recursive(300, 20);
List<TextSegment> segments = splitter.split(document);
// Convertit les chunks en embeddings
EmbeddingModel embeddingModel = ... ;
List<Embedding> embeddings =
    embeddingModel.embedAll(segments).content();
// Ajoute embeddings et chunks dans magasin embeddings
EmbeddingStore<TextSegment> embeddingStore = ... ;
embeddingStore.addAll(embeddings, segments);
```


88

Présentation des types (1/2)

- `Document` : un texte ; par exemple le contenu d'un fichier local ou d'une page Web
- `DocumentParser` : sait lire les données d'un certain type ; par exemple les données au format PDF ou les données au format Office Microsoft
- « *`UnDocumentLoader`* » : crée un Document à partir de données provenant d'une source (fichier local, page Web, …) au format supporté par le `DocumentParser`
- `DocumentSplitter` : découpe un `Document` en une liste de chunks (`List<TextSegment>`)

89

Présentation des types (2/2)

- `EmbeddingModel` : modèle d'embeddings qui peut convertir des mots, phrases, documents en `Embeddings` ; peut créer une `List<Embedding>` à partir d'une `List<TextSegment>`
- `EmbeddingStore` : magasin d'embeddings (BD vectorielle, ou autre type de magasin) qui contient des embeddings, leur segment et d'éventuelles métadonnées

90

- Création des documents

91

Interface `Document`

- Package dev.langchain4j.data.document
- Représente un texte ; souvent le contenu d'un fichier local ou d'une page Web
- Le format du fichier peut être un simple fichier texte, un PDF, un docx, ...
- Des métadonnées peuvent être attachées au document (classe `Metadata` qui est une enveloppe pour une `Map`) ; par exemple, la source du document, sa date de création, son auteur

92

Classe `TextSegment`

- Package dev.langchain4j.data.segment
- Représente un morceau de texte d'une entité plus large, avec ses éventuelles métadonnées
- Création avec méthodes `static from` auquel on passe le texte d'origine :
  - `from(String texte, Metadata metadata)` (`metadata` est un paramètre optionnel)
- Getters
  - `String text()` pour extraire le contenu
  - `Metadata metadata()`

93

Classe `Metadata`

- Package dev.langchain4j.data.document
- Métadonnées d'un `Document` ou d'un `TextSegment`
- Pour un document, ça peut être la date de création, le propriétaire, ...
- Pour un segment, ça peut être un numéro de page, la position du segment dans le document, le chapitre, ...
- Les métadonnées sont enregistrées comme une `Map` avec les clés de type `String` et les valeurs de type `String`, `UUID`, `Long`, `Float`, `Double` (valeur `null` interdite)

94

Classe `DocumentLoader`

- Package dev.langchain4j.data.document
- Pour charger un document
- Une seule méthode `static` pour charger le document

```
Document load(DocumentSource source,
              DocumentParser parser)
```


95

Interface `DocumentSource`

- Package dev.langchain4j.data.document
- Source pour obtenir un `Document`
- 2 méthodes :
  - `InputStream inputStream() throws IOException` lit le contenu du document
  - `Metadata metadata()` retourne les métadonnées associées avec la source du document
- Nombreuses implémentations : `FileSystemSource`, `UrlSource`, `GitHubSource`, `AmazonS3Source`, ...

96

Interface DocumentParser

- Package dev.langchain4j.data.document
- Pour parser un `InputStream` en un `Document`
- Une seule méthode
  `Document parse(InputStream inputStream)`
- Plusieurs implémentations :
  `ApachePdfBoxDocumentParser` (fichiers PDF), `ApachePoiDocumentParser` (fichiers doc, docx, ppt, pptx, xls, xlsx), `ApacheTikaDocumentParser` (fichiers PDF, doc, ppt, xls), `TextDocumentParser` (fichiers texte)

97

Classes utilitaires

- Des classes permettent de charger des documents des types les plus utilisés, sans implémenter `DocumentSource` :
  - `FileSystemDocumentLoader`
  - `ClassPathDocumentLoader`
  - `UrlDocumentLoader`
  - `GitHubDocumentLoader`
  - `AmazonS3DocumentLoader`
  - …

98

Exemples création document

```
// Charger un document local
Path path = Paths.get("/path/to/some/file.txt");
Document document =
    FileSystemDocumentLoader
    .loadDocument(path, new TextDocumentParser());

// Charger depuis le Web
URL url = new URL("https://...");
Document documentHtml =
    UrlDocumentLoader.load(url, new TextDocumentParser());
HtmlToTextDocumentTransformer transformer =
    new HtmlToTextDocumentTransformer(null, null, true);
Document documentText = transformer.transform(documentHtml);
```


99

FileSystemDocumentLoader

- Package dev.langchain4j.data.document.loader
- Classe utilitaire pour transformer en `Documents` des fichiers locaux dont on donne le chemin
- Méthodes `static` surchargées
  - `loadDocument` pour charger un document
  - `loadDocuments` pour charger les documents d'un répertoire
  - `loadDocumentsRecursively` pour charger les documents d'un répertoire (et des sous-répertoires)
- Chemin des fichiers ou du répertoire par `String` ou `Path`
- Paramètres optionnels pour le parser du document (`DocumentParser`) ou pour filtrer avec un pattern de nom de fichier (`PathMatcher`)

100

Exemples avec PathMatcher

```
• List<Document> documents = FileSystemDocumentLoader
      .loadDocuments("/home/langchain4j/documentation");
• PathMatcher pathMatcher = FileSystems.getDefault()
      .getPathMatcher("glob:*.pdf");
  List<Document> documents = FileSystemDocumentLoader
      .loadDocuments("/home/langchain4j/documentation",
                     pathMatcher);
• PathMatcher pathMatcher = FileSystems.getDefault()
      .getPathMatcher("glob:**.pdf");
  List<Document> documents = FileSystemDocumentLoader
      .loadDocumentsRecursively(
          "/home/langchain4j/documentation",
          pathMatcher);
```


101

Classe FileSystemSource

- Package dev.langchain4j.data.document.source
- Juste pour donner un exemple d'implémentation de `DocumentSource`
- Constructeur pour prend un `java.nio.file.Path` en paramètre ; on peut aussi utiliser les méthodes static from avec un de ces paramètres : `File`, `String`, `URI`, `Path`
- Méthodes :
  - `InputStream inputStream()`
  - `Metadata metadata()`

102

UrlDocumentLoader

- 2 méthodes `load static` surchargées :
  - `Document load(String url, DocumentParser)`
  - `Document load(java.net.URL url, DocumentParser)`
- Le `DocumentParser` à utiliser est le plus souvent un `TextDocumentParser`
- Si on veut ensuite ne pas récupérer les balises HTML, il faut transformer le `Document` avec un `HtmlToTextDocumentTransformer` (voir exemple déjà donné sur DocumentLoader)

103

HtmlToTextDocumentTransformer

- Implémente `DocumentTransformer` (une seule méthode `Document transform(Document)`
- Le constructeur peut prendre en paramètre
  - Un sélecteur CSS (type `String`), par exemple « #page-content » pour extraire le texte d'une partie de la page
  - Une `Map<String, String>` de sélecteurs CSS. Une clé peut être « titre » et sa valeur « #page-title » pour extraire le texte de l'élément d'id « #page-title » et l'enregistrer en métadonnée de clé « titre »
  - Un `boolean` qui indique si les liens de la page (pas les contenus des liens) doivent être inclus dans le texte extrait

104

- Découper les `Documents` en morceaux

105

Interface DocumentSplitter

- Package dev.langchain4j.data.document
- Découpe un document en segments de texte
- Indispensable car les LMs limitent la taille du contexte, et pour améliorer la précision des réponses
- Nombreuses classes d'implémentation parmi lesquelles `DocumentByParagraphSplitter`, `DocumentBySentenceSplitter`, `DocumentByWordSplitter`, `DocumentByRegexSplitter`, `HierarchicalDocumentSplitter`

106

Classe DocumentSplitters

- Package dev.langchain4j.data.document.splitter
- Classe utilitaire pour créer un `DocumentSplitter`
- Contient 2 méthodes `static recursive` qui retournent un `DocumentSplitter` recommandé pour découper un document en segments
- Ce splitter essaie de découper le document en paragraphes et met le plus de paragraphes possibles dans chaque `TextSegment`
- Si un paragraphe est trop long pour tenir dans un segment, il est récursivement découpé en lignes, puis en phrases, puis en mots et en caractères pour tenir dans un segment
- Paramètres des méthodes : taille maxi d'un segment (en caractères ou en tokens), taille maxi du chevauchement (seulement les phrases entières sont envisagées), tokenizer qui compte les tokens dans le texte

107

Interface Tokenizer

- Package dev.langchain4j.model
- Estime à l'avance le nombre de tokens d'un texte généré par un processus ; utilisé si la taille maximum d'un segment est donnée en tokens

108

Code pour splitter

```
URL fileUrl = TestRAG.class.getResource("/...");
Path path = Paths.get(fileUrl.toURI());
Document document = FileSystemDocumentLoader
    .loadDocument(path, new TextDocumentParser());

DocumentSplitter splitter =
    // découpe en morceaux de 600 caractères,
    // sans chevauchement
    DocumentSplitters.recursive(600, 0);

List<TextSegment> segments = splitter.split(document);
List<Embedding> embeddings =
    embeddingModel.embedAll(segments).content();

embeddingStore.addAll(embeddings, segments);
```


109

Métadonnées

- Les splitters de LangChain4j ajoutent automatiquement aux segments générés une métadonnée « index » ; sa valeur est la position du segment dans le document original
- Il est possible d'ajouter d'autres métadonnées à tous les segments générés en les ajoutant au document, avant le découpage en morceaux
- Il est aussi possible d'ajouter des métadonnées à un segment particulier, après le découpage

110

Exemple (1/2)

```
String path = "example.txt";

// Ajout métadonnées lors du chargement du document
Document document =
    FileSystemDocumentLoader.loadDocument(
        Paths.get(path),
        Metadata.from("file_name", "example.txt"));

// Splitter récursif (ajoute "index" automatiquement)
DocumentSplitter splitter =
    new RecursiveDocumentSplitter(300, 0);
List<TextSegment> segments = splitter.split(document);
```


111

Exemple (2/2)

```
// Affichage des métadonnées de chaque segment
for (TextSegment segment : segments) {
  System.out.println("Segment :\n" + segment.text());
  System.out.println("Métadonnées :");
  segment.metadata().asMap().forEach(
      (key, value) ->
          System.out.println("  " + key + " = " + value));
  System.out.println("----------");
}
```


112

Utilisation des métadonnées

- 2 exemples sont donnés dans la documentation de LangChain4J
- **Filtrage par métadonnées :** https://github.com/langchain4j/langchain4j-examples/blob/main/rag-examples/src/main/java/_3_advanced/_05_Advanced_RAG_with_Metadata_Filtering_Examples.java
- A**jouter le nom du fichier dans les métadonnées** : https://github.com/langchain4j/langchain4j-examples/blob/main/rag-examples/src/main/java/_3_advanced/_04_Advanced_RAG_with_Metadata_Example.java

113

- Création des embeddings des morceaux et enregistrement dans un magasin d'embeddings

114

Interface `EmbeddingModel`

- Package dev.langchain4j.model.embedding
- Modèle d'embeddings qui crée des embeddings à partir de segments ; implémenté par de très nombreuses classes
- Méthode abstraite
  `Response<List<Embedding>> embedAll(List<TextSegment> textSegments)`
- Méthodes par défaut (`default`) :
  - `int dimension()` : renvoie dimension des embeddings
  - `Response<Embedding> embed(String text)` : renvoie embedding du texte
  - `Response<Embedding> embed(TextSegment segment)`

115

Exemples création `EmbeddingModel`

```
EmbeddingModel embeddingModel =
    new AllMiniLmL6V2EmbeddingModel();
// ou
EmbeddingModel embeddingModel =
    OllamaEmbeddingModel.builder()
        .baseUrl("http://localhost:11434")
        .modelName("llama2")
        .build();
```


116

Obtenir un embedding

```
TextSegment segment = TextSegment.from("un texte …");
Response<Embedding> response =
    embeddingModel.embed(segment)
Embedding embedding = response.content();
```

Pourquoi `Response` ?
Pourquoi ne pas obtenir directement un embedding ?

117

Classe `Response<T>`

- Package dev.langchain4j.model.output
- Représente une réponse de plusieurs types de modèle (chat, embedding, image, modération, scoring)
- Méthodes :
  - `@NonNull T content()` : récupère le contenu
  - `TokenUsage tokenUsage()` : récupère les statistiques d'usage
  - `FinishReason finishReason()`
  - `@NonNull Map<String,Object> metadata()` : récupère les éventuelles métadonnées

118

`EmbeddingStore<T>` (1/2)

- Interface du package dev.langchain4j.store.embedding
- Pour un magasin/dépôt d'embeddings
- `T` représente la classe de ce qui va être transformé en embeddings, typiquement `TextSegment`
- Méthodes `add` et `addAll` pour ajouter un ou plusieurs embeddings, avec ou sans leur texte d'origine
- Méthodes `remove` et `removeAll` pour supprimer des embeddings
- Implémenté par des classes adaptées aux BD vectorielles (Neo4j, Chroma, MongoDB,…) et par la classe `InMemoryEmbeddingStore`

119

`EmbeddingStore<T>` (2/2)

- Méthode pour chercher des embeddings similaires (pour la phase « retrieval » du RAG) ; ce que l'on cherche est défini par `EmbeddingSearchRequest` :
  `default EmbeddingSearchResult<Embedded> search(EmbeddingSearchRequest request)`

120

InMemoryEmbeddingStore<T>

- Package dev.langchain4j.store.embedding.inmemory
- Entrepôt pour embeddings (représentés par T), en mémoire centrale ; pour tests rapides sans BD vectorielle
- Pas d'indexation des embeddings ; ils sont parcourus du premier au dernier pour la recherche des embeddings similaires

Création EmbeddingStore

```
EmbeddingStore<TextSegment> embeddingStore =
    new InMemoryEmbeddingStore();
// ou
EmbeddingStore<TextSegment> embeddingStore =
    ChromaEmbeddingStore.builder()
        .baseUrl("http://localhost:8000")
        .collectionName("my-collection")
        .build();
```


Exemple ajout embeddings

```
EmbeddingModel embeddingModel =
    new AllMiniLmL6V2EmbeddingModel();
Response<List<Embedding>> response =
    embeddingModel.embedAll(segments);
List<Embedding> listeEmbedding = response.content();

EmbeddingStore<TextSegment> embeddingStore =
    new InMemoryEmbeddingStore<>();
embeddingStore.addAll(listeEmbedding, segments);
```

Classe EmbeddingSearchRequest

- Représente une requête dans un `EmbeddingStore`
- Builder et constructeur avec les paramètres de type
  - `Embedding` : embedding dont on cherche les embeddings similaires
  - `Integer` : nombre maximum d'embeddings à retourner (3 par défaut)
  - `Double` : seulement les embeddings avec un score >= à ce nombre seront retournés (compris entre 0 et 1, bornes comprises ; 0 par défaut)
  - `Filter` : filtre à appliquer aux **métadonnées** ; seuls les segments qui correspondent à ce filtre seront retournés ; pas de filtre par défaut

EmbeddingSearchResult<T>

- Package dev.langchain4j.store.embedding
- Classe générique (paramètre de type nommé `T`, `TextSegment` le plus souvent) qui représente le résultat d'une recherche dans un magasin d'embeddings
- Constructeur qui prend en paramètre une `List<EmbeddingMatch<T>>`
- Instance retournée par la méthode `search` de `EmbeddingStore<T>`
- Méthode `matches()` qui retourne une `List<EmbeddingMatch<T>>`

EmbeddingMatch<T>

- Classe qui représente un embedding retourné par une recherche, avec son score de pertinence (dérivé de la distance cosinusoïdale) par rapport à l'embedding de la recherche, son ID et son contenu d'origine (`TextSegment` le plus souvent)
- Méthodes :
  - `T embedded()` retourne le contenu d'origine
  - `Embedding embedding()` retourne l'embedding
  - `String embeddingId()` retourne id embedding dans magasin
  - `Double score()` retourne le score de pertinence

Exemple recherche plus proche

```
Embedding embeddingQuestion = embeddingModel.embed("Quel est
votre sport favori ?").content();
EmbeddingSearchRequest searchRequest =
    EmbeddingSearchRequest.builder()
        .queryEmbedding(embeddingQuestion)
        .maxResults(3)
        .build();
EmbeddingSearchResult<TextSegment> resultatRecherche =
    embeddingStore.search(searchRequest);
List<EmbeddingMatch<TextSegment>> pertinents =
    resultatRecherche.matches();
pertinents.forEach(pertinent -> {
    System.out.println(pertinent.score());
    System.out.println(pertinent.embedded().text());
});
```


127

Composants du RAG

- EmbeddingStoreIngestor (« ingesteur », collecteur de données), pipeline pour la phase 1 : découpe un document en morceaux, les enregistre dans un magasin d'embeddings
- RetrievalAugmentor (« augmenteur ») : recherche les informations pertinentes et les ajoute à la question ; utilise en particulier un ContentRetriever (récupérateur)
- Générateur : LM qui génère la réponse en utilisant ses capacités linguistiques et les informations pertinentes retrouvées

128

`EmbeddingStoreIngestor` (1/3)

- Package dev.langchain4j.store.embedding
- Pipeline responsable de l'ingestion des documents dans un magasin d'embeddings
- Il gère tout le processus : découpage en segments, génération des embeddings pour chaque segment, enregistrement des embeddings
- Il est possible d'ajouter à ce processus la transformation des documents et la transformation des segments après le découpage en segments
- Les informations nécessaires aux traitements sont transmises à la création de l'ingestor

129

`EmbeddingStoreIngestor` (2/3)

- La création de l'ingestor se fait par un builder ou un constructeur ; on indique le modèle et le magasin pour les embeddings, le splitter, des éventuels transformeurs pour le document ou/et les segments :
  - `DocumentTransformer` peut transformer le document (nettoyage, filtrage, enrichissement, extraire le texte du contenu HTML, métadonnées, ...) ; optionnel
  - `DocumentSplitter` ; optionnel
  - `TestSegmentTransformer` peut transformer les segments, par exemple pour ajouter des métadonnées
  - `EmbeddingModel`
  - `EmbeddingStore`

130

`EmbeddingStoreIngestor` (3/3)

- L'ingestion se lance avec une des méthodes `ingest`
- La méthode `ingest` prendre en paramètre un `Document` ou une liste de `Documents`
- 2 méthodes `ingest` sont `static` ; elles permettent d'indiquer un `EmbeddingStore<TextSegment>` s'il n'a pas été donné lors de la création de l'`EmbeddingStoreIngestor`
- La valeur retour des méthodes `ingest` est de type `IngestionResult`, ce qui permet de récupérer un `TokenUsage` (qui donne le nombre de tokens utilisés pendant la création des embeddings)

131

Exemple ingestion avec `EmbeddingStoreIngestor`

```
DocumentSplitter splitter =
    DocumentSplitters.recursive(600, 0);
EmbeddingModel embeddingModel =
    new AllMiniLmL6V2EmbeddingModel();
EmbeddingStore<TextSegment> embeddingStore =
    new InMemoryEmbeddingStore<>();
EmbeddingStoreIngestor ingestor =
    EmbeddingStoreIngestor.builder()
        .documentSplitter(splitter)
        .embeddingModel(embeddingModel)
        .embeddingStore(embeddingStore)
        .build();

Document document = FileSystemDocumentLoader
    .loadDocument(path, new TextDocumentParser());
ingestor.ingest(document);
```


132

Exemple avec transformations

```
EmbeddingStoreIngestor ingestor =
    EmbeddingStoreIngestor.builder()
    .embeddingModel(embeddingModel)
    .embeddingStore(embeddingStore)
    .documentSplitter(documentSplitter)
    .documentTransformer(document -> {
        document.metadata().put("user", …);
        return document;
     })
    .textSegmentTransformer(segment -> TextSegment.from(
        segment.metadata().getString(nom_fichier) + "\n"
         + segment.text(), segment.metadata()))
    .build();

List<Document> docs = FileSystemDocumentLoader
    .loadDocumentsRecursively(path);
ingestor.ingest(documents);
```


133

RAG - récupération et augmentation

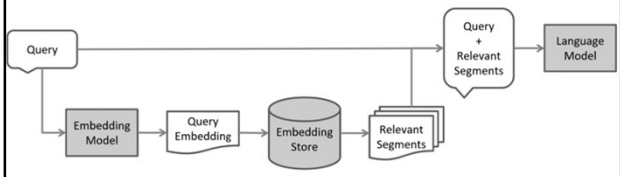

Source https://docs.langchain4j.dev/tutorials/rag

134

Exemple schématique simple

```
ContentRetriever contentRetriever =
     EmbeddingStoreContentRetriever.builder()
          .embeddingStore(embeddingStore)
          .embeddingModel(embeddingModel)
          .maxResults(2) // Nombre de résultats à retourner
          .minScore(0.5) // Score minimal pour similarité
          .build();
ChatMemory chatMemory = ... ;
Assistant assistant = AiServices.builder(Assistant.class)
    .chatModel(model)
    .chatMemory(chatMemory)
    .contentRetriever(contentRetriever)
    .build();
System.out.println(assistant.chat("..."));
```


135

Récupération

- Dans les cas les plus simples, la récupération des morceaux de texte les plus pertinents utilise un `ContentRetriever`
- Celui-ci utilise un `RetrievalAugmentor` par défaut
- Pour les cas les plus complexes, utiliser un `RetrievalAugmentor`
- Il faut choisir ; une erreur sera lancée si on indique à la fois un `ContentRetriever` et un `RetrievalAugmentor` pour l'assistant

136

Interface `ContentRetriever`

- Retrouve des contenus (des `TextSegments`) d'une source de données, pertinents pour un `Query`
- La source de données peut être
  - un magasin d'embeddings
  - un moteur de recherche dans du texte
  - un moteur de recherche sur le Web
  - un graphe de connaissance
  - une BD relationnelle
  - etc.
- Une seule méthode qui retourne le contenu retrouvé, trié par pertinence, les plus pertinents en premiers `List<Content> retrieve(Query)`

137

Implémentations `ContentRetriever`

- `EmbeddingStoreContentRetriever` : retrouve depuis un `EmbeddingStore`
- `WebSearchContentRetriever` : retrouve depuis le Web, en utilisant un `WebSearchEngine`
- `SqlDatabaseContentRetriever` : génère des requêtes SQL qui correspondent à des requêtes exprimées en langage naturel (attention, danger !)
- `Neo4jContentRetriever` : utilise Neo4j, une BD orientée graphe
- `AzureAiSearchContentRetriever` : utilise le service de recherche de Azure (fournisseur de cloud)

138

Classe Query

- Package dev.langchain4j.rag.query
- Représente une question posée par l'utilisateur pour retrouver des `Contents`
- 2 constructeurs avec ces paramètres (on peut aussi utiliser les méthodes `static from` avec les mêmes paramètres) :
  - `String`
  - `String` et `Metadata`
- 2 méthodes
  - `String txt()`
  - `Metadata metadata()`

Classe Metadata

- Package dev.langchain4j.rag.query ; ne pas confondre avec la classe du package dev.langchain4j.data.document
- Métadonnées utilisées pour retrouver des informations (utilisée par `Query`) ou pour augmenter une question posée par l'utilisateur (avant d'envoyer la requête au LM)
- Constructeur (ou méthode `static from`) avec les paramètres de type `UserMessage`, `Object` (`chatMemoryId` peut être utilisé pour distinguer les utilisateurs), `List<ChatMessage>` (chatMemory pour les messages précédents du chat, pour fournir du contexte)
- 3 « getters » `userMessage()`, `chatMemoryId()`, `chatMemory()`

Content

- Package dev.langchain4j.rag.content
- Représente un contenu pertinent pour un `Query`
- Uniquement pour `TextSegment` pour le moment, en attendant d'autres types de données (images, audio, …)
- Constructeur avec un paramètre de type `String` ou `TextContent` ; une méthode `static from` avec les mêmes paramètres permet aussi de créer une instance
- Méthode `TextSegment textSegment()` pour récupérer le `TextSegment`

EmbeddingStoreContentRetriever

- Classe du package dev.langchain4j.rag.content.retriever
- `EmbeddingStoreContentRetriever` : retrouve depuis un `EmbeddingStore` ; par défaut, retrouve les 3 `Contents` les plus pertinents, sans filtre ; créé avec un builder
- Méthodes du builder pour donner un nom, un nombre maximum de résultats, un score minimum de pertinence, un filtre (`Filter`) pour les métadonnées, un filtre dynamique (fonction qui peut dépendre du `Query`, de l'utilisateur, …)

Interface Filter

- Package dev.langchain4j.store.embedding.filter
- Pour filtrer les **métadonnées**
- Seule la méthode `boolean test(Object)` est abstraite et on peut donc utiliser une expression lambda ; elle teste si un objet satisfait le filtre
- Méthodes `static and`, `not`, `or` ; méthode default `and`, `or` qui correspondent aux méthodes `static`, avec `this` comme filtre gauche
- Implémentée par `And`, `IsEqualTo`, `IsGreaterThan`, `IsGreaterThanOrEqualTo`, `IsIn`, `IsLessThan`, `IsLessThanOrEqualTo`, `IsNotEqualTo`, `IsNotIn`, `IsTextMatch`, `IsTextMatchPhrase`, `Not`, `Or`

Exemple de filtre dynamique

```
Function<Query, Filter> filterByUserId =
   (query) -> metadataKey("userId")
              .isEqualTo(query.metadata()
              .chatMemoryId().toString());
...
ContentRetriever contentRetriever =
    EmbeddingStoreContentRetriever.builder()
    .embeddingStore(embeddingStore)
    .embeddingModel(embeddingModel)
    // La recherche sera limitée aux segments qui
    // appartiennent à l'utilisateur en cours
    .dynamicFilter(filterByUserId)
    .build();
```

WebSearchContentRetriever

- Package dev.langchain4j.rag.content.retriever
- Retrouve depuis le Web, en utilisant un `WebSearchEngine`
- Méthodes du builder pour le nombre maximum de résultats et pour le `WebSearchEngine`
- La seule méthode est celle de l'interface `ContentRetriever` :
  `List<Content> retrieve(Query query)`

145

Interface WebSearchEngine

- Package dev.langchain4j.web.search
- Représente un moteur de recherche sur le Web
- 2 méthodes
  - `WebSearchResults search(WebSearchRequest webSearchRequest)`, la seule méthode abstraite
  - `default WebSearchResults search(String query)`
- Implémentée par les classes `GoogleCustomWebSearchEngine`, `SearchApiWebSearchEngine`, `TavilyWebSearchEngine`

146

Interface WebSearchRequest

- Package dev.langchain4j.web.search
- Représente une requête envoyée à un moteur de recherche sur le Web ; suit le standard OpenSearch
- Méthode principale pour créer une requête :
  - `from(String searchTerms[, Integer maxResults])`

147

Interface WebSearchResults

- Package dev.langchain4j.web.search
- Représente le résultat d'une requête de recherche sur le Web

148

Ce que peut faire un RAG avancé

- Chunks enregistrés dans plusieurs magasins d'embeddings
- Données recherchées sur le Web
- Recherche des documents dans toutes les sources ou bien privilégier certaines sources, suivant le contenu des questions
- Reranking pour réordonner plus finement les informations récupérées
- Utilisation d'un filtrage et classement différent, suivant le type de source utilisé
- …

149

RetrievalAugmentor

- `RetrievalAugmentor` est l'élément de haut niveau responsable de coordonner les étapes de la phase 2 du RAG avancé :
  1. Prend une requête utilisateur (Content)
  2. Utilise un `ContentRetriever` pour trouver les documents pertinents
  3. Utilise un `ContentInjector` (par exemple un `DefaultContentInjector`) pour construire le prompt enrichi
  4. Passe ce prompt à un modèle (ou à un agent)

150

RetrievalAugmentor

- Schéma des différentes étapes (optionnelles) :
  - Récrire le prompt, par exemple avec des techniques de prompt engineering ou le découper en plusieurs `Query`s
  - Router vers les bons récupérateurs pour trouver les informations pertinentes
  - Agréger les informations retrouvées
  - Ajouter les informations au prompt
  - Passer le prompt au LLM

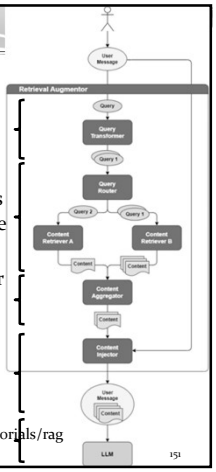

Source image https://docs.langchain4j.dev/tutorials/rag

151

Utilisation RetrievalAugmentor

- Le désigner lors de la création d'un AI service :

```
Assistant assistant =
  AiServices.builder(Assistant.class)
  ...
  .retrievalAugmentor(retrievalAugmentor)
  .build();
```


152

Interface RetrievalAugmentor

- Package dev.langchain4j.rag
- Une seule méthode :
  - `AugmentationResult augment(AugmentationRequest augmentationRequest)`
    `augmentationRequest` contient le `ChatMessage` à augmenter
- Implémentée par `DefaultRetrievalAugmentor` qui devrait convenir dans la majorité des cas

153

Class AugmentationRequest

- Package dev.langchain4j.rag
- Représente une requête pour une augmentation de `ChatMessage`
- Constructeur avec paramètres de type `ChatMessage` et `Metadata` (du package `dev.langchain4j.rag.query`)
- 2 « getters » `ChatMessage chatMessage()`, `MetaData metadata()`

154

Class AugmentationResult

- Package dev.langchain4j.rag
- Représente le résultat d'une augmentation
- 2 getters :
  - `ChatMessage chatMessage()` : message d'origine, éventuellement récrit
  - `List<Content> contents()` : les ajouts

155

DefaultRetrievalAugmentor (1/2)

- Package dev.langchain4j.rag
- Classe qui organise le flot entre ces composants :
  1. Un `QueryTransformer` pour transformer le `Query` (obtenu avec le `UserMessage`, le prompt de départ)
  2. Un `QueryRouter` va router le `Query` vers un ou plusieurs des `ContentRetriever`s
  3. Les `Contents` retrouvés sont alors transformés par un `ContentAggregator` en une liste finale de `Contents`
  4. Un `ContentInjector` ajoute la liste au `UserMessage`

156

DefaultRetrievalAugmentor (2/2)

- Chaque composant (à part `ContentRetriever`) est initialisé avec une classe d'implémentation par défaut, par exemple `DefaultQueryTransformer`
- D'autres classes avancées d'implémentation sont fournies par LangChain4j, par exemple `CompressingQueryTransformer` ou `ExpandingQueryTransformer`

157

QueryTransformer

- Interface du package dev.langchain4j.rag.query.transformer
- Transforme un `Query` en un ou plusieurs Query
- Pour plus de détails : https://blog.langchain.dev/query-transformations/

158

QueryRouter

- Interface du package dev.langchain4j.rag.query.router
- Une seule méthode : `Collection<ContentRetriever> route(Query query)` qui route vers un ou plusieurs `ContentRetriever`, selon la question (`Query`)
- L'aiguillage peut être fait par un LM, un modèle d'embeddings, par des mots-clés, par l'utilisateur qui pose la question (`query.metadata().chatMemoryId()`) ou par les autorisations
- Implémentée par 2 classes `DefaultQueryRouter` `LanguageModelQueryRouter`

159

DefaultQueryRouter

- Package dev.langchain4j.rag.query.router
- Constructeur qui prend en paramètre un ou plusieurs `ContentRetriever`
- La méthode `route` renvoie tous les `ContentRetriever`
- Intéressant si on veut utiliser plusieurs types de `ContentRetriever` pour récupérer des documents pour le RAG

160

LanguageModelQueryRouter

- Choix du ou des `ContentRetrievers` fait par un LM
- Si la connexion au LM ou si le LM donne une réponse non valable, on peut donner une stratégie de fallback (de repli) : pas de RAG, lancer une exception, router vers tous les `ContentRetrievers`
- Builder pour créer une instance ; on peut passer
  - une `Map<ContentRetriever, String>` qui décrit chaque `ContentRetriever`
  - un `ChatLanguageModel`, celui qui décide
  - un `PromptTemplate` pour poser la question au LM
  - une stratégie de repli

161

Exemple de routage

```
// 2 ContentRetrievers pour retrouver les informations
// à ajouter au prompt
// Descriptions associées à chacun des ContentRetriever
Map<ContentRetriever, String> descriptions =
    new HashMap<>();
descriptions.put(contentRetriever1,
                 "Conditions pour départ en retraite");
descriptions.put(contentRetriever2,
                 "Règles pour travail à distance");
QueryRouter queryRouter =
    new LanguageModelQueryRouter(chatModel,
                                 descriptions);
```

Les descriptions aideront le LM à choisir le bon `ContentRetriever` pour chaque question posée

162

QueryRouter personnalisé

- Il faut implémenter l'interface `QueryRouter`
- Donc implémenter la méthode `Collection<ContentRetriever> route(Query query)`
- Le paramètre est la question envoyée au LM ; la méthode retourne le ou les `ContentRetriever` qui seront utilisés pendant la phase de récupération du RAG
- Souvent la classe sera une classe interne à la méthode qui l'utilise ; classe anonyme ou pas
- L'exemple suivant indique qu'il ne faut pas de RAG si la question de l'utilisateur ne porte pas sur l'IA

163

Exemple classe interne

```
class QueryRouterPourEviterRag implements QueryRouter {
  @Override
  public List<ContentRetriever> route(Query query) {
    String question =
        "Est-ce que la requête '" + query.text()
        + "' porte sur l'IA ? Réponds seulement par"
        + " 'oui', 'non', ou 'peut-être'.";
    String reponse = model.chat(question);
    if (reponse.toLowerCase().contains("non")) {
      // Pas de RAG (aucun ContentRetriever utilisé)
      return Collections.emptyList();
    } else {
      return Collections.singletonList(contentRetriever);
    }
  }
}
```

164

Interface ContentAgregator

- Package dev.langchain4j.rag.content.aggregator
- Réunit tous les `Contents` retrouvés par tous les `ContentRetriever` afin de sélectionner les plus pertinents
- Par exemple pour faire du reranking
- Une méthode `List<Content> aggregate(Map<Query,Collection<List<Content>>> queryToContents)`
- Implémentée par `DefaultContentAggregator`, `ReRankingContentAggregator`

165

DefaultContentAgregator

- Implémentation de `ContentAgregator` qui convient dans la plupart des cas

166

ReRankingContentAggregator

- Package dev.langchain4j.rag.content.aggregator
- Effectue un reranking en utilisant un `ScoringModel`
- Peut-être configuré en donnant le score minimum d'un `Content` pour qu'il soit retenu

167

Interface ScoringModel

- Package dev.langchain4j.model.scoring
- Attribue un score de similarité par rapport à un texte sous la forme d'une `Response`
- Une méthode abstraite
  `Response<List<Double>> scoreAll(List<TextSegment> segments, String query)`
- 2 méthodes `default`
  - `Response<Double> score(String text, String query)`
  - `Response<Double> score(TextSegment segment, String query)`

168

Exemple pour reranking (1/2)

```
ScoringModel scoringModel = CohereScoringModel.builder()
                .apiKey(cohereKey)
                .modelName("rerank-multilingual-v3.0")
                .build();

ContentAggregator contentAggregator =
    ReRankingContentAggregator.builder()
                .scoringModel(scoringModel)
                .minScore(0.6)
                .build();
```


169

Exemple pour reranking (2/2)

```
RetrievalAugmentor retrievalAugmentor =
    DefaultRetrievalAugmentor.builder()
                .contentRetriever(contentRetriever)
                .contentAggregator(contentAggregator)
                .build();

AiServices.builder(Assistant.class)
                .chatModel(modele)
                .retrievalAugmentor(retrievalAugmentor)
                .chatMemory(memory)
                .build();
```


170

Interface `ContentInjector`

- Package dev.langchain4j.rag.content.injector
- Injecte des `Contents` dans un `UserMessage`
- Permet d'ajouter au prompt les informations pertinentes récupérées dans les étapes précédentes
- Une seule méthode

```
ChatMessage inject(List<Content> contents,
                   ChatMessage chatMessage)
```


171

Classe `DefaultContentInjector`

- Package dev.langchain4j.rag.content.injector
- Implémentation par défaut de `DefaultContentInjector`
- Ajoute les `Contents` à la fin du `UserMessage`, dans l'ordre de la liste (voir `DEFAULT_PROMPT_TEMPLATE`)
- Constructeurs et pattern builder pour créer une instance ; on peut indiquer un template (avec variables `{{userMessage}}` et `{{contents}}`) et une liste de clés pour métadonnées qui seront ajoutées à chaque segment (`Content.textSegment()`)

172

Références

173

- RAG explained : embedding, sentence BERT, vector database par Umar Jamil : https://www.youtube.com/watch?v=rhZgXNdhWDY
- RAG et fine-tuning : https://learn.microsoft.com/fr-fr/azure/developer/ai/augment-llm-rag-fine-tuning
- RAG avancé : https://learn.microsoft.com/fr-fr/azure/developer/ai/advanced-retrieval-augmented-generation
- Quelques exemples d'utilisation du RAG : https://www.cohesity.com/fr/glossary/retrieval-augmented-generation-rag/

174

- Méthodes avancées de RAG : https://fr.linkedin.com/pulse/m%C3%A9thodes-avanc%C3%A9es-de-g%C3%A9n%C3%A9ration-augment%C3%A9e-par-rag-ilan-bompuis-ynoof

175